Resumen y conclusiones del paper

Salazar-Coronel et al. (2026), *Soil Organic Carbon Content Mapping along the Coast of Northern Peru: An Ensemble Machine Learning Approach*

Jean Marcos Huaroto Romero

Inteligencia Artificial Aplicada (1INF62)
Proyecto: predicción de Carbono Orgánico del Suelo (`ORGC`) con AllpaDB

1. Referencia

Salazar-Coronel, W., Carbajal-Llosa, C. y Chuchon-Remon, R. (2026). Soil organic carbon content mapping along the coast of northern Peru: An ensemble machine learning approach. *Frontiers in Soil Science*, 6, Artículo 1745154. DOI: 10.3389/fsoil.2026.1745154. Estudio realizado en la cuenca del río Motupe (Lambayeque), en la costa norte del Perú.
Enlace directo: `https://doi.org/10.3389/fsoil.2026.1745154`

2. Problema y objetivo

El carbono orgánico del suelo (SOC) es un indicador básico de la calidad del suelo, pero su distribución es muy variable en los ecosistemas secos y en el Perú hay pocos análisis a escala de cuenca. El estudio estima y mapea el SOC de la cuenca del Motupe (3 673,66 km^2, desde el nivel del mar hasta 3 500 m s. n. m.) con cuatro algoritmos (SVR, Random Forest, red neuronal y XGBoost) y dos ensambles (promedio simple y promedio ponderado), y mide la incertidumbre con bootstrap. Para nuestro proyecto es el antecedente más cercano en la variable objetivo: el SOC del paper (carbono orgánico medido por combustión seca y expresado en %) es la misma propiedad que nuestro `ORGC`, es decir, una concentración de carbono orgánico y no un stock. La única precaución es confirmar la unidad y el método de laboratorio de `ORGC` en AllpaDB, aunque su mediana (0,69) sugiere que también está en %.

3. Datos y predictores

- 109 muestras compuestas (cuatro submuestras por punto), tomadas entre septiembre y diciembre de 2023 en puntos aleatorios. El paper no indica la profundidad de muestreo.
- Variable objetivo SOC en %, con rango de 0,42 a 0,87 (media de 0,65 y desviación estándar de 0,11).
- 19 predictores candidatos: relieve (DEM de 30 m), propiedades del suelo medidas en laboratorio (BD, pH, CE, arcilla, limo y arena) interpoladas por kriging, clima (temperatura y precipitación) e índices de vegetación (NDVI, SAVI, GNDVI y EVI) de Sentinel-2.
- El VIF mayor a 10 dejó 13 variables y la eliminación recursiva (RFE) con Random Forest dejó 11. Las más importantes fueron EVI, GNDVI, temperatura, TRI y pH.
- Las coordenadas no se usaron como predictores.

4. Metodología

1. Selección de variables con VIF y RFE (Random Forest de 500 árboles, validación de diez bloques repetida tres veces).

2. Estandarización z-score de todos los predictores.
3. Modelos: SVR con kernel RBF, Random Forest, red neuronal de una capa oculta (`nnet`) y XGBoost, con búsqueda en malla de 134 combinaciones en total.
4. Validación espacial en bloques: una malla de 3×3 (nueve bloques) repartida en cinco pliegues, con las predicciones de todos los pliegues juntas para calcular las métricas.
5. Ensambles: promedio simple y promedio ponderado, con pesos proporcionales al R^2 de la validación espacial.
6. Métricas: RMSE, MAE, R^2 y CCC de Lin. Incertidumbre con bootstrap de 10 iteraciones y razón de intervalo de predicción (PIR).
7. Dos escenarios: A, con 11 covariables (incluye pH, CE, arcilla y limo interpolados), y B, solo con 7 covariables ambientales.

5. Resultados para SOC

	Escenario A		Escenario B	
Modelo	RMSE	R^2	RMSE	R^2
SVR	0,105	0,004	0,102	0,806
ANN	0,113	0,136	0,112	0,102
Random Forest	0,108	0,626	0,106	0,616
XGBoost	0,111	**0,833**	0,104	0,478
Ensamble (promedio)	0,075	0,485	0,069	0,566
Ensamble (ponderado)	**0,057**	0,702	**0,059**	0,683

Valores de la Tabla 4 del paper (validación espacial de cinco pliegues). RMSE en puntos porcentuales de SOC. El R^2 de 0,806 de SVR en el escenario B parece un error de la tabla (ver sección 7).

6. Hallazgos principales

- XGBoost fue el mejor modelo individual ($R^2 = 0{,}83$) y el ensamble ponderado el mejor en error (RMSE = 0,057; $R^2 = 0{,}70$). Random Forest llegó a 0,63, el ensamble simple a 0,49, la red neuronal a 0,14 y SVR a 0,004, es decir, casi predijo la media.
- Las correlaciones de SOC con los predictores son débiles (máximo de 0,24 con NDVI) y solo los índices de vegetación resultaron significativos.
- En Random Forest, EVI (8,75 %), GNDVI (6,30 %), temperatura (6,25 %), TRI (5,5 %) y pH (5,1 %) suman 31,9 % de la importancia. Limo y TWI fueron los menos influyentes.
- Quitar las propiedades del suelo interpoladas casi no cambió el ensamble ponderado (RMSE de 0,057 a 0,059 y R^2 de 0,70 a 0,68), porque varias se interpolan mal (BD, limo y arena con R^2 menor a 0,16 en el kriging).
- El SOC es bajo en toda la cuenca (media de 0,65 % y 55 % de arena). Los valores más altos (mayores a 0,8 %) aparecen en la parte alta, con más vegetación y lluvia, y la zona baja queda entre 0,6 y 0,7 %.
- El PIR medio fue de 0,142: incertidumbre baja en 14,89 % del área, moderada en 75,09 % y alta en 10,02 %, esta última en la zona alta.
- Los autores atribuyen el bajo desempeño de ANN y SVR a la muestra pequeña y a las restricciones del paquete `nnet`.

7. Limitaciones

- Solo 109 muestras, con menor densidad de puntos en zonas de difícil acceso, y sin covariables de alta resolución. Los datos están disponibles solo a pedido a los autores.
- Lectura propia (a revisar): las cifras no son coherentes entre sí. La sección 3.5 y la Figura 7 dan RMSE de 0,002 a 0,011, mientras que la Tabla 4 da de 0,057 a 0,113. Como la desviación estándar del SOC es 0,106, un RMSE de 0,111 no mejora a predecir la media, y eso no calza con un R^2 de 0,83. La Figura 7 parece mostrar el ajuste en entrenamiento y no predicciones fuera de muestra.
- Posible fuga de información: el VIF, la RFE, el kriging de las propiedades del suelo y los pesos del ensamble se calcularon con todos los datos o con la misma validación que luego se usa para evaluar.
- Hay otras incoherencias: el R^2 de 0,83 que la sección 4.3 asigna al ensamble ponderado (antes era 0,70) y las conclusiones, que cuentan cuatro modelos sobre 0,60 cuando el ensamble simple tiene 0,49.
- El bootstrap de incertidumbre usó regresión lineal, Random Forest y árboles de decisión, no los modelos finales.
- Los predictores de teledetección y relieve no existen en AllpaDB (solo coinciden pH, textura, CE y densidad aparente), por lo que los resultados no son comparables de forma directa.

8. Conclusiones

Con covariables fáciles de obtener, los autores generan un mapa de SOC para una cuenca de bosque seco, con XGBoost, el ensamble ponderado y Random Forest como mejores opciones, mientras que ANN y SVR rinden poco con 109 puntos. Los índices de vegetación, la temperatura, el relieve y el pH son los predictores más relevantes. Por las inconsistencias descritas en la sección 7, los R^2 reportados deben tomarse con cautela. El aporte principal para nuestro trabajo es de diseño: validación espacial, varios algoritmos, un ensamble y escenarios con y sin un grupo de variables.

9. Implicancias para nuestros baselines

Aspecto	Lo que hizo el paper	Propuesta para nuestro proyecto
Baseline simple	No incluye predictor de la media ni modelo lineal	Predictor de la media y Regresión Lineal Múltiple como pisos de rendimiento
Modelos de ML	SVR, RF, ANN y XGBoost con búsqueda en malla	RF como baseline fuerte, XGBoost como comparación y MLP como tercer modelo, con variables escaladas
Ensambles	Promedio simple y ponderado por el R^2 de la misma validación	Probar un ensamble con pesos calculados solo con datos de entrenamiento
Validación	Cinco pliegues en bloques espaciales; coordenadas fuera de los predictores	Validación cruzada de cinco bloques agrupada por perfil; por bloques espaciales solo si se logran unir coordenadas a AllpaDB
Preprocesamiento	VIF, RFE y escalamiento con todos los datos	Selección de variables y escalamiento dentro de cada partición, ajustados solo con entrenamiento
Métricas	RMSE, MAE, R^2 y CCC	RMSE, MAE y R^2, en entrenamiento y prueba
Referencia de desempeño	XGBoost con R^2 de 0,83 sobre SOC de 0,42 a 0,87 %	Usarla solo como referencia cualitativa: el rango y los predictores son distintos y las cifras del paper no son coherentes

Baselines propuestos, en orden

1. **Predictor de la media:** piso absoluto; un modelo con R^2 de 0 o menos no aporta nada frente a él.
2. **Regresión Lineal Múltiple:** mide cuánto aporta la no linealidad. En el paper las correlaciones lineales con SOC son bajas.
3. **Random Forest:** modelo de árboles de referencia, que además entrega importancia de variables.
4. **XGBoost:** alternativa de boosting, el mejor modelo individual del paper.
5. **MLP:** equivalente a la ANN del paper; en el paper rindió mal con 109 puntos, así que hay que vigilar el sobreajuste.
6. Opcionales: SVR con kernel RBF y un ensamble de los mejores modelos.

Recomendaciones metodológicas tomadas del paper

- Comparar todos los modelos con las mismas particiones y las mismas métricas, con una validación que respete la estructura de los datos para no sobreestimar el desempeño.
- Ajustar la selección de variables, el escalamiento y cualquier ponderación solo con los datos de entrenamiento de cada partición.
- Analizar la importancia de variables del mejor modelo e interpretarla con conocimiento edáfico (por ejemplo, el rol de la vegetación y del pH).
- Reportar entrenamiento y prueba, y comprobar que RMSE y R^2 sean coherentes con la dispersión del objetivo antes de dar por buenos los resultados.