Resumen y conclusiones del paper

Carbajal et al. (2024), *From Rangelands to Cropland, Land Use Change and Its Impact on Soil Organic Carbon Variables in a Peruvian Andean Highlands: A Machine Learning Modeling Approach*

Juan Pablo Huaman Chara
Código: 20227179

Inteligencia Artificial Aplicada (1INF62)
Proyecto: predicción de Carbono Orgánico del Suelo (`ORGC`) con AllpaDB

1. Referencia

Carbajal, M., Ramírez, D. A., Turin, C. y otros (2024). *Ecosystems*, 27, 899 a 917. DOI: 10.1007/s10021 024 00928 7. Estudio realizado en los Andes centrales de Junín, Perú.
Enlace directo: `https://link.springer.com/article/10.1007/s10021-024-00928-7`

2. Problema y objetivo

Los suelos altoandinos almacenan mucho carbono orgánico (SOC), pero hay pocos modelos predictivos para esta región. El estudio compara cuatro algoritmos de aprendizaje automático para predecir tres variables de carbono: SOC, SOC refractario (RSOC) y la composición isotópica δ^{13}C del SOC. Para nuestro proyecto solo es relevante el modelado de SOC, que equivale a nuestro `ORGC`.

3. Datos y predictores

- 198 muestras compuestas de suelo a 0,3 m de profundidad, en 800 km^2 cerca del Lago Junín. Muestreo por Hipercubo Latino.
- Variable objetivo SOC en %, con rango de 1,67 a 17,77.
- 42 predictores candidatos: tipo de uso y cobertura del suelo (LULC, nueve categorías), textura (arena, limo, arcilla), pH, distancia al lago, clima (WorldClim), bandas e índices espectrales (Landsat 8) y topografía (DEM, pendiente, TWI).
- Boruta dejó 23 predictores para SOC. Los más importantes fueron LULC ("bofedales"), índices espectrales (SER2, NDMI, MSAVI, NDVI) y la distancia al lago.

4. Metodología

1. Selección de variables con Boruta (basado en Random Forest).
2. Partición en cinco bloques (75 % entrenamiento y 25 % prueba), estratificada según el valor del objetivo.
3. Escalamiento (estandarización y normalización) aplicado incluso a los modelos de árboles.

4. Modelos: Random Forest (RF), red neuronal artificial (ANN), máquina de vectores de soporte (SVM) y XGBoost (XGB), con ajuste de hiperparámetros mediante validación cruzada, implementados en R con `caret`.
5. Métricas: R^2 y RMSE, promediadas sobre las cinco particiones.
6. Al final se reentrenó el mejor modelo con todos los datos para interpretar la importancia de variables.

5. Resultados para SOC

	Entrenamiento		Prueba	
Modelo	RMSE	R^2	RMSE	R^2
Random Forest	0,77	0,87	**1,47**	**0,49**
ANN	1,15	0,70	1,49	0,43
SVM	1,11	0,72	1,66	0,36
XGBoost	0,92	0,81	1,53	0,42

6. Hallazgos principales

- RF fue el mejor modelo para SOC en prueba (R^2 = 0,49; RMSE = 1,47 %). La ANN fue la mejor solo para RSOC.
- Hay una brecha grande entre entrenamiento (R^2 hasta 0,87) y prueba (0,36 a 0,49): sobreajuste por la muestra pequeña.
- La diferencia entre algoritmos en prueba es pequeña (RMSE de 1,47 a 1,66), por lo que los autores señalan que el tamaño de muestra pesa más que el algoritmo elegido.
- Los bofedales (humedales altoandinos) tienen de 2 a 3 veces más SOC que otros usos del suelo, y fueron el predictor más importante.
- La textura (arcilla y limo) fue descartada por Boruta, y el pH fue relevante sobre todo para RSOC y δ^{13}C.
- Los R^2 de la literatura para SOC suelen estar entre 0,24 y 0,68, y los RMSE reportados entre 0,59 y 2,7.

7. Limitaciones

- Solo 198 muestras, una sola profundidad y una sola fecha de imagen satelital.
- Las particiones se hicieron por valor del objetivo, no por sitio ni por perfil.
- Los predictores principales (LULC e índices espectrales) no existen en AllpaDB, por lo que los resultados no son comparables de forma directa.

8. Conclusiones

Los modelos de aprendizaje automático capturan relaciones no lineales del SOC con desempeño aceptable y consistente. RF es el algoritmo más prometedor para SOC en los Andes peruanos. El rendimiento está limitado por la cantidad de datos y por las covariables disponibles, por lo que más datos y mejores predictores son la vía principal de mejora.

9. Implicancias para nuestros baselines

Aspecto	Lo que hizo el paper	Propuesta para nuestro proyecto
Baseline simple	No incluye modelo lineal	Regresión Lineal Múltiple como referencia mínima
Modelo principal	Random Forest	Random Forest como baseline fuerte de árboles
Boosting	XGBoost, R^2 de prueba 0,42	XGBoost como comparación con ajuste de hiperparámetros
Red neuronal	ANN, R^2 de prueba 0,43	MLP como tercer modelo, con variables escaladas
Otro clásico	SVM, R^2 de prueba 0,36	SVR o KNN como baseline adicional opcional
Validación	Cinco bloques estratificados por objetivo	Validación cruzada de cinco bloques agrupada por perfil, para evitar fuga entre capas
Preprocesamiento	Escalamiento aplicado a todos los modelos	Pipelines con y sin escalamiento, ajustados solo con entrenamiento
Métricas	R^2 y RMSE	R^2, RMSE y MAE, en entrenamiento y prueba
Referencia de desempeño	R^2 de prueba de 0,36 a 0,49, RMSE de 1,47 %	Usarlo como cota de comparación, esperando mejorar con 24 341 registros

Baselines propuestos, en orden

1. **Regresión Lineal Múltiple:** piso de rendimiento y punto de comparación para medir cuánto aporta la no linealidad.
2. **Random Forest:** mejor modelo del paper para SOC, y además entrega importancia de variables.
3. **XGBoost:** alternativa de boosting con desempeño cercano a RF en el paper.
4. **MLP:** equivalente a la ANN del paper, usada para ver si captura patrones que los árboles no.

Recomendaciones metodológicas tomadas del paper

- Comparar todos los modelos con las mismas particiones y las mismas métricas.
- Reportar entrenamiento y prueba para mostrar el sobreajuste.
- Analizar la importancia de variables del mejor modelo e interpretarla con conocimiento edáfico (por ejemplo, el rol del pH).
- Evitar fuga de información dividiendo por perfil, algo que el paper no controló.