# Resumen y conclusiones del paper

**Carbajal et al. (2025), Spatial Prediction of Soil Organic Carbon Stocks across Contrasting Andean Basins, Peru**

Susan Sayli Lozano Bernardo
Código: 20215871
Inteligencia Artificial Aplicada (1INF62)
Proyecto: predicción de Carbono Orgánico del Suelo (ORGC) con AllpaDB

## 1. Referencia

Carbajal, C., Tumbalobos-Dextre, M., Condori-Ataupillco, T., Cuellar-Condori, N. y Gavilan, C. (2025). *Geoderma Regional*, 43, e01026. DOI: 10.1016/j.geodrs.2025.e01026. Estudio realizado en dos cuencas altoandinas del sur del Perú: Torobamba (Ayacucho) y Coata (Puno).

Enlace directo: https://doi.org/10.1016/j.geodrs.2025.e01026

## 2. Problema y objetivo

Los suelos altoandinos almacenan mucho carbono, pero su dinámica está poco estudiada y la fuerte heterogeneidad espacial del terreno montañoso dificulta cuantificarlo y mapearlo. El estudio compara modelos de regresión geoespacial y de aprendizaje automático para predecir el stock de carbono orgánico del suelo (SOCS, en Mg $ha^{-1}$, a 30 cm): Regresión Ponderada Geográficamente (GWR), GWR con análisis de colinealidad (GWRC), sus variantes con kriging de residuos (GWRK y GWRCK), Random Forest (RF) y Gradient Boosting (GB).

Para nuestro proyecto es relevante la comparación entre modelos que usan la ubicación de forma explícita y modelos de ML que no la usan. Hay una diferencia de variable objetivo: el paper predice el *stock* (SOC en % × densidad aparente × profundidad), mientras que nuestro ORGC es una concentración.

## 3. Datos y predictores

- Dos cuencas: Torobamba (1040,47 $km^2$, 1500 a 4500 msnm, cuatro zonas ecológicas, 536 mm de lluvia anual) y Coata (460,16 $km^2$, 3825 a 4250 msnm, solo zona Puna, 751 mm).
- 100 sitios en Torobamba y 96 en Coata, elegidos por Hipercubo Latino condicionado (cLHS). En cada sitio, cinco submuestras en un radio de 5 m, mezcladas en una muestra compuesta, a 30 cm de profundidad; la densidad aparente (BD) se midió con anillo de 5 cm × 5 cm.
- SOC por combustión seca (analizador LECO CN828) y BD por el método del cilindro. SOCS (Mg $ha^{-1}$) = SOC (%) × BD (Mg $m^{-3}$) × profundidad (cm).
- Torobamba: SOC de 2,52 % (DE 1,04; rango 0,83 a 5,16) y BD de 1,24 Mg $m^{-3}$. Coata: SOC de 1,34 % (DE 0,39; rango 0,52 a 2,42) y BD de 1,32 Mg $m^{-3}$.
- 21 covariables candidatas: topografía (DEM ALOS PALSAR de 30 m, con SAGA y *elevatr*), clima (WorldClim v2.1: temperatura media anual y precipitación), temperatura superficial (LST, Landsat 8) y nueve índices espectrales de Landsat 8 (NDVI, TSAVI, SATVI, GNDVI, EVI, SAVI, NDWI, BSI, BI2).
- Selección: se eliminó una de cada par con correlación mayor a 0,90 y luego se descartaron iterativamente las variables con VIF mayor a 10. Quedaron nueve covariables por cuenca. En ambas cuencas aparecen SATVI, BSI, profundidad de valle (V_depth), altura normalizada (N_height), LS_factor, TPI y las curvaturas de plano y perfil; BI2 solo entró en Torobamba y TWI solo en Coata.

## 4. Metodología

1. Selección de variables por correlación y VIF en R 4.4.3, hecha una sola vez antes de modelar.
2. GWR con núcleo gaussiano y ancho de banda por validación cruzada (paquete *spgwr*). Ancho óptimo: 55 023,57 m en Torobamba y 40 064,74 m en Coata.
3. GWRC: GWR con regresión de cresta compensada localmente (paquete *GWmodel*), núcleo bisquare adaptativo y umbral de número de condición (CN) de 25. Ancho óptimo: 63 vecinos en Torobamba y 95 en Coata.
4. Kriging de los residuos de GWR y de GWRC (paquete *automap*), lo que da GWRK y GWRCK. El kriging se aplicó solo a las variantes de GWR, no a RF ni a GB.
5. RF y GB (scikit-learn): partición 80 % entrenamiento y 20 % prueba, estandarización y búsqueda en malla (GridSearchCV) con validación cruzada de cinco bloques. La malla de GB: 100, 200 o 500 árboles; tasa de aprendizaje 0,01, 0,1 o 0,2; profundidad 3, 4 o 5.
6. Métricas: RMSE, MAE y $R^2$. Luego se generaron mapas de SOCS por píxel y se resumieron por cobertura del suelo (ESA WorldCover 10 m, 2021).

## 5. Resultados para SOCS

**Torobamba (100 sitios)**

| Modelo | RMSE | MAE | $R^2$ |
|---|---|---|---|
| GWR | 31,28 | 26,76 | 0,14 |
| GWRK | 6,52 | 5,57 | 0,96 |
| GWRC | 25,26 | 20,70 | 0,44 |
| **GWRCK** | **2,48** | **2,02** | **0,99** |
| Random Forest | 29,29 | 26,11 | 0,11 |
| Gradient Boosting | 30,67 | 27,57 | 0,03 |

**Coata (96 sitios)**

| Modelo | RMSE | MAE | $R^2$ |
|---|---|---|---|
| GWR | 15,60 | 12,74 | 0,17 |
| GWRK | 14,37 | 11,74 | 0,30 |
| GWRC | 14,89 | 12,21 | 0,25 |
| **GWRCK** | **13,43** | **11,01** | **0,39** |
| Random Forest | 14,19 | 13,15 | -0,01 |
| Gradient Boosting | 16,01 | 14,75 | -0,28 |

*RMSE y MAE en Mg $ha^{-1}$. En negrita, el mejor modelo de cada cuenca. Valores tomados de la Tabla 5 del paper.*

## 6. Hallazgos principales

- GWRCK fue el mejor modelo en ambas cuencas: en Torobamba redujo el RMSE de GWRC en 90,17 % (de 25,26 a 2,48) y llegó a un $R^2$ de 0,99; en Coata la mejora fue modesta (RMSE de 14,89 a 13,43, $R^2$ de 0,39).
- Casi toda la ganancia viene del kriging de residuos. GWR sin kriging explica poco: $R^2$ de 0,14 en Torobamba y 0,17 en Coata, y los $R^2$ locales varían apenas entre 0,133 y 0,141 (Torobamba) y entre 0,164 y 0,189 (Coata).

- RF y GB tuvieron mal desempeño: $R^2$ de 0,11 y 0,03 en Torobamba, y negativos en Coata (-0,01 y -0,28), es decir, peores que predecir la media. Los autores lo atribuyen a la selección de variables, el ajuste de hiperparámetros, la muestra pequeña o la falta de covariables espaciales.
- Los modelos de ML producen rangos de predicción más estrechos que GWR (Torobamba: 71,8 a 122,95 con RF y 68,3 a 124,72 con GB, frente a 37,31 a 173,97 con GWRK), por lo que no capturan toda la variabilidad.
- Los coeficientes de GWR cambian de signo según la ubicación (no estacionariedad espacial). GWRC da rangos de coeficientes mucho más amplios (por ejemplo, curvatura de plano en Torobamba: de -583,62 a 690,22 en GWR frente a -13 224 a 10 612,41 en GWRC), con números de condición entre 17,8 y 27,3, lo que exige interpretar los coeficientes con cuidado.
- Variables más importantes en ML: V_depth fue la más relevante o una de las más relevantes en ambas cuencas; SATVI y BSI aparecen en los primeros lugares de RF y GB; en Torobamba también destacan TPI y LS_factor (GB), y en Coata TWI y N_height. Los autores explican que la topografía controla la erosión, la acumulación y la humedad del suelo.
- Torobamba tiene más SOC (2,52 % frente a 1,34 %) y menor BD que Coata, con un terreno más heterogéneo; en Coata el terreno es más homogéneo y GWR aporta menos.
- Por cobertura del suelo, las tierras de cultivo tienen los SOCS más bajos en ambas cuencas (con los modelos GWR), y matorral y cobertura arbórea los más altos.

## 7. Limitaciones

- Solo 100 y 96 muestras, una sola profundidad (0 a 30 cm) y dos cuencas, sin prueba de transferencia entre regiones. Los datos están disponibles solo a pedido al autor.
- Los $R^2$ locales de GWR son bajos (0,13 a 0,19) y los coeficientes de GWRC son inestables, con números de condición de 20 a 28.
- La comparación entre familias de modelos no es equivalente: GWR usa las coordenadas y el kriging, mientras que RF y GB no reciben información espacial. Los propios autores reconocen la falta de covariables espaciales en ML.
- **Lectura propia (a revisar):** el paper no deja claro cómo se validó GWRK/GWRCK. El resumen habla de validación cruzada de cinco bloques, pero el diagrama del método indica validación “en los puntos de muestreo” y RF y GB se evaluaron con partición 80/20. Si el kriging se ajustó con los mismos puntos donde se calcula el error, los $R^2$ de 0,96 y 0,99 estarían inflados, porque el kriging reproduce los valores observados en sus propios puntos.
- La selección de variables (correlación y VIF) se hizo con todos los datos antes de particionar, lo que puede filtrar información al conjunto de prueba. Tampoco se detalla la malla de hiperparámetros de RF.
- Los predictores del paper (índices espectrales de Landsat 8, LST) no existen en AllpaDB, por lo que los resultados no son comparables de forma directa.

## 8. Conclusiones

Los modelos de GWR con kriging de residuos superaron a RF y GB en las dos cuencas, sobre todo con muestras pequeñas y terreno complejo, y GWRK/GWRCK capturaron mejor la heterogeneidad espacial. RF y GB, sin mecanismos espaciales explícitos, rindieron poco. Los autores recomiendan explorar modelos híbridos que integren ponderación espacial y ML, y subrayan que los stocks altos de carbono en los suelos andinos justifican caracterizarlos mejor. Aun así, la validación descrita limita cuánto se puede generalizar la ventaja de GWRK/GWRCK (ver sección 7).

## 9. Implicancias para nuestros baselines

| Aspecto | Lo que hizo el paper | Propuesta para nuestro proyecto |
|---|---|---|
| **Baseline simple** | No incluye modelo lineal global ni la media como referencia | Predictor de la media y Regresión Lineal Múltiple como pisos de rendimiento |
| **Modelos de ML** | RF y GB con partición 80/20 y GridSearchCV; $R^2$ de 0,11 y 0,03 (Torobamba) y negativos (Coata) | RF como baseline fuerte, XGBoost o GB como comparación y MLP como tercer modelo, con variables escaladas |
| **Información espacial** | GWR con coordenadas y kriging de residuos (GWRK, GWRCK) | Probar coordenadas como variables y RF con kriging de residuos, ajustando el kriging solo con datos de entrenamiento |
| **Validación** | Evaluación en los puntos de muestreo y partición 80/20, sin esquema común | Validación cruzada de cinco bloques agrupada por perfil y, además, por bloques espaciales para evitar fuga entre puntos cercanos |
| **Preprocesamiento** | Correlación y VIF con todos los datos antes de particionar | Selección de variables y escalamiento dentro de cada partición, ajustados solo con entrenamiento |
| **Métricas** | RMSE, MAE y $R^2$ | RMSE, MAE y $R^2$, en entrenamiento y prueba |
| **Referencia de desempeño** | Coata: $R^2$ de 0,39 (GWRCK) y RMSE de 13,43 Mg $ha^{-1}$ | Usarla solo como referencia cualitativa, porque su variable objetivo es stock y la nuestra es concentración; el valor de 0,99 de Torobamba no sirve como cota |

### Baselines propuestos, en orden

1. Predictor de la media: piso absoluto; los $R^2$ negativos de RF y GB en Coata muestran que un modelo puede quedar por debajo de él.
2. Regresión Lineal Múltiple: punto de comparación para medir cuánto aporta la no linealidad.
3. Random Forest: modelo de árboles de referencia, además de entregar importancia de variables.
4. XGBoost: alternativa de boosting (el paper usó Gradient Boosting).
5. MLP: equivalente a una red neuronal, para ver si captura patrones que los árboles no.
6. Opcional: RF con coordenadas y kriging de residuos, inspirado en GWRK, para medir cuánto aporta la información espacial.

### Recomendaciones metodológicas tomadas del paper

- Comparar todos los modelos con las mismas particiones y las mismas métricas, algo que el paper no hizo entre GWR y ML.
- Incorporar la dimensión espacial de forma explícita y evaluarla sin fuga: el kriging y la selección de variables deben ajustarse solo con los datos de entrenamiento de cada partición.
- Analizar la importancia de variables del mejor modelo e interpretarla con conocimiento edáfico (por ejemplo, el papel de la topografía y de la vegetación).
- Reportar entrenamiento y prueba, y tratar con cautela los $R^2$ cercanos a 1 en muestras pequeñas.